

Dokumen Pengujian — ocr-engine

Peran pemilik dokumen: @quality-assurance Versi service: 0.1.0 Tanggal eksekusi terakhir: 14 September 2026 Hasil: 39 lolos, 0 gagal, 21,88 detik

1. Ruang Lingkup

Yang diuji adalah `ocr-engine/` : satu service yang menerima berkas dan mengembalikan teks beserta koordinat dan confidence per kata. Pemetaan teks menjadi field dokumen bukan tanggung jawab service ini dan tidak diuji di sini.

Yang diuji:

Area	Bentuk pengujian
Pemilihan jalur pemrosesan	Text layer PDF, raster PDF, gambar
Validasi berkas	Tipe menurut magic bytes, ukuran, jumlah halaman
Preprocessing	Deskew, denoise, koreksi perspektif, upscale, binarisasi, morfologi
Bentuk respons	Struktur, normalisasi <code>bbox</code> , nilai <code>confidence</code> , <code>engine</code> per jalur
Isi bacaan	Kata kunci yang harus muncul pada dokumen fixture
Penanganan kesalahan	Berkas rusak, tipe tidak didukung, melebihi batas

Yang tidak diuji:

Area	Alasan
Akurasi terhadap dokumen asli	Belum ada golden dataset. Seluruh fixture adalah dokumen buatan
Observability	Logging terstruktur, tracing, dan metrik belum diimplementasikan
Beban dan konkurensi	Belum ada target throughput yang ditetapkan
Keamanan ingress	Service ini tidak memiliki ingress; validasi paranoid berada di layanan pintu masuk

2. Strategi

Tiga hal yang membentuk cara pengujian ini disusun:

1. **Berjenjang.** Fungsi preprocessing diuji satuan dengan gambar sintetis yang sifatnya diketahui (kotak putih pada latar hitam, teks yang sengaja dimiringkan 10°). Jalur ujung ke ujung diuji dengan berkas fixture menyerupai dokumen nyata. Fungsi satuan menjelaskan **kenapa** gagal, uji ujung ke ujung menjelaskan **bahwa** gagal.
2. **Dapat dijalankan tanpa Tesseract.** Uji yang membutuhkan biner Tesseract diberi marker `ocr` dan dilewati otomatis bila binernya tidak ada (`tests/conftest.py`). Dengan begitu kontributor tanpa Tesseract tetap dapat menjalankan suite dan CI Linux tetap berguna.
3. **Fixture ter-commit, bukan dibuat ulang saat uji.** Berkas fixture dihasilkan oleh `tests/fixtures/generate_fixtures.py` yang membutuhkan font Times New Roman dari Windows.

Berkas hasilnya di-commit sebagai baseline bersama; skripnya ada untuk menerangkan asal-usul dan membuat varian baru.

3. Lingkungan Pengujian

Komponen	Versi
Python	3.9.13
Tesseract	5.4.0.20240606 (leptonica 1.84.1)
OpenCV	4.10.0 (opencv-python-headless)
PyMuPDF	1.26.5
FastAPI	0.128.8
Pydantic	2.13.5
pytest	8.4.2
Sistem operasi	Windows 11

Konfigurasi preprocessing saat eksekusi: deskew **nyala**, denoise **nyala**, koreksi perspektif **nyala**, upscale 300 DPI **nyala**, binarisasi adaptif **mati**, morfologi **mati**.

4. Cara Menjalankan

```
pip install -r requirements-dev.txt

pytest                # seluruh uji
pytest -v             # dengan nama tiap kasus
pytest -m "not slow"  # lewati OCR halaman penuh (lebih cepat)
pytest -m ocr         # hanya yang membutuhkan Tesseract
pytest tests/test_preprocess.py::TestPreprocessSteps::test_deskew_corrects_known_skew
```

Marker yang dipakai: `ocr` (butuh biner Tesseract) dan `slow` (OCR satu halaman penuh, hitungan detik).

5. Daftar Kasus Uji

5.1 `test_health.py` — 1 kasus

Kasus	Yang dikunci
<code>test_health_ok</code>	<code>/health</code> mengembalikan 200 dan tepat empat kunci. Uji ini menangkap kebocoran informasi bila kelak ada yang menambahkan detail internal ke respons health

5.2 test_mime_detection.py — 4 kasus

Kasus	Yang dikunci
test_accepts_allowed_types	JPG, PNG, dan PDF diterima
test_rejects_unknown_signature	Berkas dengan magic bytes asing ditolak. Tipe ditentukan dari isi berkas, bukan dari ekstensi atau Content-Type kiriman klien
test_rejects_oversized_image	Gambar > 10 MB ditolak FILE_TOO_LARGE
test_rejects_oversized_pdf	PDF > 25 MB ditolak FILE_TOO_LARGE

5.3 test_pdf_text.py — 4 kasus

Kasus	Yang dikunci
test_pdf_text_layer_creator	PDF ber-text-layer memberi ocr_source = text_layer, engine = null, dan jumlah kata yang tepat. engine null membuktikan tidak ada OCR yang dijalankan
test_exact_text_match	Nomor surat dan tempat tujuan terbaca persis. Inilah keunggulan jalur ini: tidak ada karakter yang ditebak
test_bounding_box_always_normalized	Seluruh bbox berada di rentang 0–1 dan confidence = 1,0
test_deny_pdf_without_text	PDF kosong ditolak sebagai text layer tidak memadai, sehingga dialihkan ke jalur OCR alih-alih mengembalikan halaman kosong

5.4 test_pdf_raster.py — 9 kasus

Kasus	Yang dikunci
test_converts_rgb_to_bgr	Konversi pixmap PyMuPDF (RGB) ke urutan kanal OpenCV (BGR). Tertukarnya kanal tidak membuat program gagal, hanya menurunkan akurasi diam-diam
test_rejects_invalid_pdf	Berkas teks biasa ditolak INVALID_PDF
test_rejects_over_page_limit	Melebihi PDF_MAX_PAGES ditolak, tidak dipotong diam-diam
test_returns_ocr_response	ocr_source = ocr, engine terisi, duration_ms > 0
test_reads_document_content	Judul, tempat tujuan, dua nama pegawai, dan satu NIP 18 digit terbaca
test_reads_document_number	Nomor surat 090/ST/IX/2026 terbaca lengkap dengan garis miringnya
test_rasters_at_configured_dpi	A4 pada 300 DPI menghasilkan sekitar 2480 x 3508 piksel
test_bbox_is_normalized	Seluruh koordinat berada di rentang 0–1
test_reads_every_page	PDF dua halaman menghasilkan dua halaman berurutan, dan isi halaman kedua (lampiran beserta nominalnya) ikut terbaca

5.5 test_image_ocr.py — 5 kasus

Kasus	Yang dikunci
test_decodes_png	PNG terdekode menjadi larik tiga kanal
test_rejects_undecodable_bytes	Berkas ber-magic-bytes PNG tetapi isinya rusak ditolak UNSUPPORTED_MEDIA_TYPE , bukan melempar galat mentah
test_returns_ocr_response	Bentuk respons dan identitas mesin
test_recognizes_rendered_text	Teks yang digambar ke citra terbaca kembali
test_bbox_is_normalized	Seluruh koordinat berada di rentang 0–1

5.6 test_preprocess.py — 16 kasus

Fungsi satuan:

Kasus	Yang dikunci
test_deskew_returns_image_and_angle	Bentuk keluaran deskew
test_deskew_corrects_known_skew	Kemiringan +10° terdeteksi dengan toleransi 1°
test_deskew_corrects_negative_skew	Kemiringan –7° terdeteksi. Uji ini menjaga penanganan tanda sudut, sumber bug klasik pada minAreaRect
test_deskew_leaves_horizontal_text_untouched	Gambar lurus dikembalikan identik , tanpa rotasi 0° yang tetap mengaburkan piksel karena interpolasi
test_denoise_returns_same_shape	Denoise tidak mengubah dimensi atau tipe data
test_adaptive_threshold_returns_binary	Keluaran hanya bernilai 0 dan 255
test_upscale_to_dpi_increases_size	Upscale ke 300 DPI memperbesar gambar
test_upscale_to_dpi_no_change_when_scale_le_1	Target lebih kecil dari sumber tidak memperkecil gambar
test_morphological_cleanup_returns_same_shape	Morfologi tidak mengubah dimensi
test_perspective_restores_aspect_ratio	Halaman yang difoto menyudut dikembalikan ke rasio aslinya dengan toleransi 15%

Orkestrasi:

Kasus	Yang dikunci
<code>test_returns_preprocess_result</code>	Seluruh atribut hasil tersedia untuk pencatatan diagnostik
<code>test_steps_applied_contains_enabled_steps</code>	Langkah yang menyala tercatat di <code>steps_applied</code>
<code>test_input_output_resolution_recorded</code>	Resolusi sebelum dan sesudah tercatat
<code>test_duration_ms_positive</code>	Durasi terukur
<code>test_output_image_is_binary_after_threshold</code>	Dengan binarisasi menyala, keluaran benar-benar biner
<code>test_threshold_and_morphology_skipped_when_disabled</code>	Saklar konfigurasi benar-benar mematikan langkahnya

6. Pengujian Manual Terhadap Dokumen Kusut

Di luar suite otomatis, dua fixture foto dokumen kusut dikirim ke endpoint `POST /ocr` untuk melihat perilaku pada kondisi buruk. Hasil pada foto kusut ringan dijadikan acuan, lalu dibandingkan dengan foto kusut berat.

Bagian	Kusut ringan	Kusut berat	Dampak
Nomor telepon kop	3449230,	3449230:	Ringan
Garis kop	Tidak terbaca	Terbaca sebagai deretan simbol	Kata sampah
Golongan pegawai 1	III-b	1II-D	Nilai rusak
Golongan pegawai 2	III-c	III-€	Nilai rusak
Label tanggal	Tanggal , Kembali	Tanggal , Kembati	Jangkar parser hilang
Lama perjalanan	: 4 (empat) hari	"4 Cempat) hari	Pemisah hilang
Pembebanan anggaran	DIPA Ditjen ...	Kata DIPA hilang	Nilai salah tanpa penanda

Yang tetap benar pada kedua foto: seluruh NIP, seluruh tanggal, seluruh nama, dan nomor surat.

Tiga temuan yang memengaruhi rancangan sistem

- confidence** tidak dapat dipakai sebagai penanda kesalahan. Kata `3449230:` yang salah bernilai 0,90, sedangkan `Pangkat/Golongan` yang benar bernilai 0,48 dan `Santoso` yang benar bernilai 0,53. Nilai ini mengukur keyakinan pengenalan bentuk huruf, bukan kebenaran isinya. Penanda "perlu diperiksa" di aplikasi tidak boleh hanya bersandar pada angka ini.
- Kata yang hilang adalah kegagalan paling berbahaya.** `Ditjen Perbendaharaan TA 2026` tampak wajar sehingga tidak ada mekanisme hilir yang dapat mengetahui bahwa `DIPA` pernah ada. Perbaikannya harus di preprocessing, bukan di pemrosesan teks.
- Binarisasi adaptif merugikan pada konfigurasi saat ini.** Dengan `blockSize` tetap 11 pada gambar yang sudah diperbesar sekitar empat kali, bagian dalam goresan huruf tebal menjadi putih. Karena itu `PREPROCESS_THRESHOLD` dimatikan secara bawaan dan Tesseract dibiarkan membinarisasi sendiri.

7. Batasan Pengujian Ini

Fixture bukan pengukur akurasi. Seluruh berkas uji dihasilkan program dengan satu tata letak, satu font, tanpa stempel, tanpa kop berlogo, tanpa kertas menguning, dan tanpa tulisan tangan. Fixture menutup jalur kode dan mengunci regresi — lolosnya seluruh uji **tidak** berarti akurasi sistem memadai.

Angka akurasi yang sah hanya dapat diperoleh dari dokumen asli. Pengumpulan dokumen contoh nyata masih menjadi pertanyaan terbuka pada dokumen produk, dan menjadi prasyarat sebelum akurasi dapat diklaim.

Data pada seluruh fixture bersifat fiktif: nama, NIP, dan nomor surat dikarang untuk keperluan uji.

8. Rekomendasi Lanjutan

#	Rekomendasi	Alasan
1	Kumpulkan golden dataset dokumen asli beserta teks acuannya	Tanpa itu, tidak ada angka akurasi yang dapat dipertanggungjawabkan
2	Ukur akurasi per field, bukan hanya tingkat kesalahan karakter	Satu karakter salah pada NIP jauh lebih merugikan daripada satu karakter salah pada uraian tugas
3	Uji varian preprocessing secara berdampingan: resolusi sumber sebenarnya, tanpa binarisasi, normalisasi pencahayaan	Tiga tuas ini paling berpengaruh pada foto dokumen kusut dan berbayang
4	Tambahkan uji untuk observability setelah diimplementasikan	Termasuk memastikan teks hasil OCR tidak pernah masuk log
5	Tambahkan uji batas jumlah halaman pada jalur text layer	Saat ini batas hanya diperiksa pada jalur raster
6	Uji beban setelah target throughput ditetapkan	OCR bersifat CPU-bound; perilaku saat banyak permintaan bersamaan belum diketahui